

ROB lab 5, 6 Rozpoznawanie odzieży z wykorzystaniem sieci neuronowych Paweł Paczusi (271082)

Rozpoznawanie odzieży z wykorzystaniem sieci neuronowych

Zadanie polegało na implementacji sieci neuronowej w celu klasyfikacji odzieży. Zbiorem danych był fashion-MNIST zawierający 10 rodzajów odzieży w identycznym formacie jak zbiór MNIST z cyframi.

Wariant standardowy

Celem było uzyskanie sieci neuronowej, której uda się uzyskać lepsze wyniki niż:

Zbiór uczący:

Poprawne	Błędne
90.38%	9.62%

Zbiór testowy:

Poprawne	Błędne
87.42%	12.58%

Aby uzyskać lepsze wyniki zbudowano sieć neuronową o dwóch warstwach (1 ukryta 1 wyjściowa) z 400 neuronami w warstwie ukrytej, tempo uczenia 0.025 przez 70 epok:

Zbiór uczący

Poprawne	Błędne
94.19%	5.81%

Zbiór trenujący

Poprawne	Błędne
88.81%	11.19%

Każda epoka zajmowała około 157 s, więc sumarycznie wytrenowanie sieci zajęło dużo czasu (3 h).

Modyfikacja rozwiązania w celu uzyskania lepszych wyników

Zmienne tempo uczenia

Pierwszym pomysłem było wprowadzenie zmiennego współczynnika uczenia sieci. Zastosowano proste rozwiązanie polegające na zmniejszaniu współczynnika błędu o 10%, gdy sieć zaczynała zwracać gorsze wyniki niż w poprzedniej epoce. Uczenie przebiegało bardzo powoli, ale przebiegało. Sieć uczyła się aż przez 200 epok i uzyskiwała lepsze wyniki niż rozwiązanie, które należało pokonać. Uczenie rozpoczęło z wartością tempa uczenia 0.25 i zmniejszano je aż do wartości 0.0005

Zbiór testowy

Poprawne	Błędne
97.28%	2.72%

Zbiór treningowy

Poprawne	Błędne
89.13%	10.87%

Warto zwrócić uwagę na zbytne dopasowanie sieci do danych. Chociaż jest to wynik spełniający oczekiwania, to podjęto dalsze poszukiwania rozwiązania, które nie dopasowywałoby się tak bardzo do danych treningowych lub pozwalałoby osiągać zbliżone wyniki szybciej.

Normalizacja danych

W celu poprawy wyników podjęto próbę normalizacji danych treningowych testowych, jednak to rozwiązanie przyniosło znaczne pogorszenie wyników, więc zostało odrzucone – sieć oscylowała wokół 20% błędów na zbiorze testowym.

Standaryzacja

Kolejnym pomysłem było dodanie do zmiennego tempa uczenia standaryzacji danych: od każdej próbki odjęto średnią wartość z jej kolumny i podzielono przez odchylenie standardowe kolumny.

Parametry:

- 400 neuronów
- 200 epok
- startowe tempo uczenia 0.25
- spadek tempa uczenia 10%
- minimalne tempo uczenia 0.0005;

Już po 33 epokach osiągnięto obiecujące efekty

Zbiór trenujący

Poprawne	Błędne
97.13%	2.87%

Zbiór testowy

Poprawne	Błędne
88.87%	11.13%

Wyniki są nieco gorsze od najlepszego uzyskanego za pomocą usprawnień rozwiązania, ale potrzeba mniej epok aby uzyskać lepsze niż zadane rozwiązanie. Jedna epoka trwała 150 s.

Podjęto próbę przyspieszenia rozwiązania – zmniejszono liczbę neuronów do 250, przyspieszono zmniejszanie tempa uczenia oraz zmniejszono startowe tempo uczenia.

Parametry:

- 250 neuronów
- 50 epok
- startowe tempo uczenia 0.1
- spadek tempa uczenia 30%
- minimalne tempo uczenia 0.0005;

Dzięki zmniejszeniu liczby neuronów, jedna epoka trwała 92 s – prawie dwukrotne przyspieszenie. Sieć osiąga najlepsze rozwiązanie przy 42. epoce, następnie oscyluje wokół tego rozwiązania.

Zbiór trenujący

Poprawne	Błędne
97.57%	2.43%

Zbiór testujący

Poprawne	Błędne
89.01%	10.99%

Wnioski

Dostrajanie parametrów sieci może znacząco zmienić przebieg jej uczenia. W razie potrzeby dalszej poprawy klasyfikacji zawsze można skorzystać ze sztuczek korzystających z obserwacji właściwości używanych danych. Kolejnym krokiem usprawniającym działanie sieci mogłoby być zastosowanie regularyzacji w celu ograniczenia nadmiernego dopasowania, które w uzyskanym rozwiązaniu jest duże.

Wybrane rozwiązanie jest lepsze od rozwiązań referencyjnych i w przeciwieństwie do najlepszego ze wszystkich uzyskanych, osiągnęte jest stosunkowo szybko przy niewielkiej różnicy błęd.